

# Долгосрочное домашнее задание

Свиридов Иван СКБ 182

14 декабря 2020 г.

# 1. Домашнее задание. Вероятностные распределения

## 1.1. Равномерное дискретное распределение

### 1.1.1. Основные понятия

Дискретное равномерное распределение:  $P(x) = N^{-1}$ ,  $x \in [1, \dots, N]$ ,  $(P(x) = P(\xi = x_i) = p_i)$   
Найдем функцию распределения  $A$  для нашего дискретного равномерного распределения по определению:

**Исправлено:**

---

$F_\xi(x) = P(\xi \leq x) \Rightarrow$  Применим для нашего распределения  $\Rightarrow$

$$F_\xi(x) = \begin{cases} 0, & \text{при } x < 1 \\ \sum_{i: x_i \leq x} P(x_i) & 1 \text{ при } x \leq N \\ 1, & \text{при } x > N \end{cases} \Rightarrow \begin{cases} 0, & \text{при } x < 1 \\ \frac{\lfloor x \rfloor}{N} & 1 \text{ при } x \leq N \\ 1, & \text{при } x > N \end{cases}$$

---

-т.к  $F_\xi(x) = 0$ , при  $x < 1$

$$\lim_{x \rightarrow -\infty} F_\xi(x) = 0$$

-т.к  $F_\xi(x) = 1$ , при  $x > N$

$$\lim_{x \rightarrow \infty} F_\xi(x) = 1$$

-функция не является непрерывной, так как наблюдается разрыв типа "скачок"

**Def:** Математическое ожидание (среднее значение, первый момент) случайной величины  $\xi$  с дискретным распределением называется число  $M_\xi = \sum x_i p_i = \sum x_i P(\xi = x_i)$ , если данный ряд сходится абсолютно, то есть, если  $\sum x_i \cdot p_i < \infty$ , иначе не существует.

Для нашего равномерного дискретного распределения:  $M_\xi = \sum_{i=1}^N x_i \cdot p_i = \sum_{i=1}^N x_i \cdot \frac{1}{N} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{1}{N} \cdot \frac{1}{2} \cdot N \cdot (N+1) = \frac{N+1}{2}$

**Def:** Дисперсия случайной дискретной величины  $\xi$  - число:  $D_\xi = M(\xi - M_\xi)^2 = \sum_{i=1}^N p_i (x_i - M_\xi)^2$ , по смыслу - среднее значение квадрата отклонения  $\xi$  от своего среднего.

Для нашего равномерного дискретного распределения:  $D_\xi = \sum_{i=1}^N p_i (x_i - M_\xi)^2 = M_\xi^2 - (M_\xi)^2 =$  (в силу

линейности  $M_\xi = \sum_{i=1}^N x_i^2 \cdot p_i = \frac{(N+1)^2}{4} =$

$$= \frac{1}{6} \cdot (N+1)(2N+1) - \frac{(N+1)^2}{4} = (N+1) \cdot \left( \frac{1}{6} \cdot 2N + \frac{1}{6} \cdot \frac{N}{4} - \frac{1}{4} \right) = (N+1) \cdot \left( \frac{4N-3N+2-3}{12} \right) = (N+1) \cdot \left( \frac{N-1}{12} \right) = \frac{1}{12} \cdot (N^2 - 1) = \frac{N^2 - 1}{12}$$

**Def:** Мода распределения случайной дискретной величины  $\xi$  - величина, которая равна значению (случайной величины) с наибольшей вероятностью.

**Исправлено:**

---

$P_\xi(x) = \text{const} \forall x \in [1, \dots, N] \Rightarrow$  мода - любое значение из  $[1, \dots, N]$

**Def:** Медиана распределения дискретной случайной величины  $\xi$  - величина, равная значению (случайной величины), для которого вероятность меньших значений равна вероятности больших значений.

$$M_e = \begin{cases} \# , & \forall i \in N \Rightarrow \sum_{s=1}^{i-1} P_s \neq \sum_{s=1+i}^N P_s \\ x_i, & \exists i \in N \Rightarrow \sum_{s=1}^{i-1} P_s = \sum_{s=1+i}^N P_s \end{cases}$$

Для нашего дискретного равномерного распределения:

если  $N$  - нечетное, то  $M_e = \frac{N+1}{2}$

если  $N$  - четное, то  $M_e \in [\frac{N}{2}, \frac{N}{2} + 1]$

Из этого следует, что  $M_e = \frac{N+1}{2}$

**Исправлено:**


**Def:** Производящая функция дискретной неотрицательной случайной величины - величина, равная  $M_\xi(t) = M[e^{\xi t}]$ . Для нашего равномерного дискретного распределения:

$$M_\xi(t) = \sum_{i=1}^N e^{tx_i} \cdot p_i = \sum_{i=1}^N e^{tx_i} \cdot \frac{1}{N} = \frac{1}{N} \cdot \sum_{i=1}^N e^{tx_i} = \frac{e^t(e^{Nt}-1)}{N(e^t-1)}$$

**Def:** Характеристическая функция дискретной случайной величины  $\xi$  - величина:  $\phi_\xi(t) = \sum_k e^{itx_k} \cdot p_k$

Для нашего равномерного дискретного распределения:

$$\phi_\xi(t) = \sum_{k=1}^N e^{itx_k} \cdot p_k = \sum_{k=1}^N e^{itx_k} \cdot \frac{1}{N} = \frac{1}{N} \cdot \sum_{k=1}^N e^{itx_k} = \frac{e^{it}(e^{iNt}-1)}{N(e^{it}-1)}$$



**Рис. 1:** Гистограмма распределения



**Рис. 2:** При  $n=10$

Manipulate[DiscretePlot[ $\frac{1}{N}$ , {x, 1, N}, PlotRange -> Automatic], {N, 1, 100, 1}]  
варьировать график последовательности ч... отображаем... автоматический численное прибли

Рис. 3: Код Wolfram Mathematica 12.1

### 1.1.2. Типичная и нетипичная интерпретация

#### Типичная интерпретация

Рассмотрим пример дискретного равномерного распределения:

Когда мы бросаем игральные кости, на кубе выпадает случайное ребро со своим значением. Это пример дискретного равномерного распределения, естественно, если кость "идеальна как и условия бросания. Таким образом мы рассматриваем случайную величину  $\xi$ , с законом распределения  $P_\xi = \frac{1}{N}$ ,  $x \in [1, \dots, N]$ , где  $N=6$  (у куба 6 сторон). Нас может интересовать такой вопрос, а сколько очков выпадает в среднем на игральной кости? Сформулировать этот вопрос на языке теории вероятности, мы приходим к задаче о поиске математического ожидания величины  $\xi$ . Как нам известно, математическое ожидание (или первый момент) ищется по формуле  $M_\xi = \sum_i p_i x_i$ , для нашего случая:

$$M_\xi = \sum_{i=1}^6 \frac{1}{6} x_i = \frac{1}{6} \sum_{i=1}^6 x_i = \frac{1}{6} (1+2+3+4+5+6) = \frac{24}{6} = 3,5 - \text{количество очков выпадающее в среднем на игральной кости.}$$

**Исправлено:**

---

#### Интерпретация

Представим нетипичную интерпретацию, когда мы играем с младшим братом в игру вытяни карточку с действием из шляпы. Всего существует  $N$  карточек внутри шляпы. Мы написали на каждой карточке какие-то действия. И брат вытягивает каждый раз карточку с действием. Вероятность что достанет нужное (удобное для него) действие составляет  $\frac{1}{N}$ . Так как он достает карточку в слепую, и не знает что на ней написано, то исход не зависит от человека. Из этого примера следует, что дискретным равномерным распределением можно описать игру с выбором карточки с действием из шляпы.

---

### 1.1.3. Моделирование

Реализуем выборочное значение  $\alpha$  стандартного случайного числа и полагаем  $m = [\alpha N] + 1 = [\alpha N + 1]$ . Рассмотрим теперь подход, который состоит в приведении вероятностей к общему знаменателю.

Пусть  $\xi$  — дискретное распределение с конечным, относительно небольшим количеством значений  $N$ . Пусть также все вероятности  $p_i$  — это обыкновенные дроби, которые можно привести к общему знаменателю  $M$ , то есть  $p_i = \frac{m_i}{M}$ , причем  $m_1 + \dots + m_n = M$  и  $M \leq M_0$ , где  $M_0$  — размер максимального массива для данного компьютера и языка программирования.

Рассмотрим случайную величину  $\xi'$ , такую, что  $\xi' = x'_j = x_i$  при  $j = \sum_{s=1}^{i-1} m_s + 1, \dots, \sum_{s=1}^i m_s$ , причем  $P(\xi' = x'_j) = \frac{1}{M}$ . Это значит, что первые  $m_1$  значений  $x'_j$  равна  $x_1$ , следующие  $m_2$  значит  $x'_j$  равны  $x_2$  и так далее, причем все значения  $x'_j$  равновероятны.

Выборочные значения случайной величины  $\xi'$  реализуются согласно правилу:  $\xi' = x'_m$ , при  $m' = M\alpha + 1$ .

```

import numpy
import random
from matplotlib import pyplot, axes
from statsmodels.distributions.empirical_distribution import ECDF

def generate(N=10):
    lx = []
    dic = {}
    for i in range(N):
        dic[i+1]=(i/N, (i+1)/N)
    for i in range(600):
        rand_number = random.random()
        #we need to create helpfull dictionary:
        for i in dic:
            if dic[i][0] <= rand_number < dic[i][1]:
                x = i
        lx.append(x)
    lx.sort()
    ly = []
    #counting probabilities of samples and appending to ly
    for i in range(N):
        ly.append(lx.count(i+1)/600)
        #dont need samples lx more
    lx = [i+1 for i in range(N)]

    print(lx, ly)
    pyplot.plot([i+1 for i in range(N)], [1/N for _ in range(N)], 'ro')
    axes = pyplot.axes()
    axes.set_ylim([0,1])
    pyplot.plot(lx, ly, 'go')
    pyplot.show()

generate()

```

Рис. 4: Код




Рис. 5: При  $n=10$

## 1.2. Экспоненциальное распределение

Непрерывное экспоненциальное (показательное) распределение  $f(x) = \lambda \cdot e^{-\lambda x}$   
Мода экспоненциального распределения равна нулю, так как  $f(0) = \lambda > f(x)$ ,  $\forall x > 0$   
Найдем функция распределения для показательного распределения:

$$F(x) = \int_{-\infty}^x f(x)dx = \int_{-\infty}^x \lambda e^{-\lambda x} dx = 1 - e^{-\lambda x}, (x > 0)$$

Воспользуемся уравнением  $F(Me) = \frac{1}{2}$  для нахождения медианы распределения:  
 $F(Me) = 1 - e^{-\lambda Me} = \frac{1}{2} \Rightarrow Me = \frac{\ln 2}{\lambda}$

Вычислим математическое ожидание:

$$M_\xi = \int_{-\infty}^{\infty} x f(x) dx = \lambda \int_0^{\infty} x e^{-\lambda x} dx = \lim_{b \rightarrow \infty} \left( (x + \frac{1}{\lambda}) e^{-\lambda x} \right) =$$
$$= - \lim_{b \rightarrow \infty} \left( (b + \frac{1}{\lambda}) e^{-\lambda b} \right) - \left( (0 + \frac{1}{\lambda}) e^0 \right) = - \left( 0 - \frac{1}{\lambda} \right) = \frac{1}{\lambda}$$

**Def:** Вычислим дисперсию:

$$D_\xi = \int_{-\infty}^{+\infty} x^2 f(x) dx - (M_\xi)^2$$
$$(*) \int_{-\infty}^{+\infty} x^2 f(x) dx = \lambda \int_0^{+\infty} x^2 e^{-\lambda x} dx = (*simplify*) = - \left( x^2 + \frac{2x}{\lambda} + \frac{2}{\lambda^2} \right) e^{-\lambda x} = - \lim_{b \rightarrow +\infty} \left( x^2 + \frac{2x}{\lambda} + \frac{2}{\lambda^2} \right) e^{-\lambda x} =$$
$$D_\xi = \frac{2}{\lambda^2} - \left( \frac{1}{\lambda} \right)^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

**Подправлено:**

---

**Def:** Производящая функция  $M_\xi(t)$ :

По определению:  $M_\xi(t) = M[e^{t\xi}]$ . Для нахождения, воспользуемся свойством:  
Где  $\xi$  - случайная величина,  $M[g(\xi)] = \int_{\mathbb{R}} g(x) \cdot f_\xi(x) dx$

Найдем  $M_\xi(t)$  для нашего распределения:

$$M_\xi(t) = M[e^{t\xi}] = \int_0^{\infty} e^{tx} \cdot f_\xi(x) dx = \int_0^{\infty} e^{tx} \cdot \lambda e^{-\lambda x} dx = \lambda \int_0^{\infty} e^{x(t-\lambda)} dx =$$
$$= \frac{\lambda}{\lambda - t} = \left( 1 - \frac{t}{\lambda} \right)^{-1}$$

**Def:** Характеристическая функция  $\varphi_\xi(t)$ :

По определению:  $\varphi_\xi(t) = M[e^{it\xi}]$ . Для нахождения, воспользуемся свойством:  $\int_{\mathbb{R}} e^{itx} P(x) dx$   
Найдем  $\varphi_\xi(t)$  для нашего распределения:

$$\varphi_\xi(t) = M[e^{it\xi}] = \int_0^{\infty} e^{itx} \cdot f_\xi(x) dx = \int_0^{\infty} e^{itx} \cdot \lambda e^{-\lambda x} dx = \lambda \int_0^{\infty} e^{x(it-\lambda)} dx =$$
$$= \frac{\lambda}{\lambda - it} = \left( 1 - \frac{it}{\lambda} \right)^{-1}$$

---




Рис. 6: Плотность при  $\lambda = \frac{1}{2}, 1, 2$

```
Plot[Table[PDF[ExponentialDistribution[ $\lambda$ ], x],
гра... табл... пл... показательное распределение
{ $\lambda$ , {1/2, 1, 2}}] // Evaluate, {x, -2, 5}, Filling -> Axis,
вычислить заливка ось
PlotRange -> All]
отображаем... всё
```

Рис. 7: Код Wolfram Mathematica 12.1




Рис. 8: Функция распределения при  $\lambda = \frac{1}{2}, 1, 2$

```
Plot[Table[CDF[ExponentialDistribution[λ], x],
гра... табл... ф... показательное распределение
{λ, {1/2, 1, 2}}] // Evaluate, {x, 0, 4}, Filling → Axis]
вычислить заливка ось
```

Рис. 9: Код Wolfram Mathematica 12.1



### 1.3 Типичная и нетипичная интерпретация

**Типичная интерпретация.** Рассмотрим случай, когда мы пришли в ремонтную мастерскую и нам необходимо починить персональный компьютер в течении 5 дней, а мастер говорит, что успеют починить, но возможно потребуется больше 5 дней. По заверению мастера, в среднем один компьютер чинится 3 дня. Значит наш параметр показательного распределения  $\lambda = \frac{1}{3}$ . Как бы нам не хотелось, чтобы чинили больше 5 дней, нам необходимо узнать вероятность, что на ремонт ноутбука потребуется не меньше 5 дней. Так как  $X$  - случайная величина, распределенная по показательному закону, ее функция распределения равна  $1 - e^{-\lambda x} (x > 0)$ , а вероятность попадания в интервал вычисляется по формуле показательного распределения:

$$P(a < x < b) = e^{-\lambda a} - e^{-\lambda b} = e^{-\frac{a}{3}} - e^{-\frac{b}{3}}$$

Тогда вероятность того, что на ремонт ноутбука потребуется не менее 5 дней. То есть  $X \geq 5$ , равна:

$$P(X \geq 5) = 1 - P(0 < x < 5) = 1 - (e^{-\frac{0}{3}} - e^{-\frac{5}{3}}) = 1 - 1 + e^{-\frac{5}{3}} \approx 0,189$$

Таким образом, с помощью показательного распределения мы можем определить вероятность, придется ли нам больше ждать, если нам срочно нужен ноутбук.

**Подправлено:**

---

**Нетипичная интерпретация.** Рассмотрим нетипичную интерпретацию для показательного распределения. Возьмем некоторое видео на платформе "Youtube" в интернете. И рассмотрим, как появляются комментарии под этим видео. Существует правило, что чем дольше видео находится на площадке интернет-роликов, тем реже появляются новые комментарии под этим видео. Пусть каждый новый пользователь оставляет новый комментарий независимо от других пользователей. Также оставляется не более одного комментария за малый промежуток времени.

Обозначим через  $X_s$  - число комментариев написанных под видео за определенное время  $S$ . Из выше описанных условий, будет следовать, что параметр  $\lambda$  - интенсивность появления комментариев. В данной модели ставится вопрос, а как распределено время между появлениям соседних комментариев. Из всего этого следует, что время между появлениями комментариев распределено экспоненциально. Таким образом в модели, касающейся казалось бы дискретных объектов, проявит себя экспоненциальное распределение. Анализ проводился видео от 04.11.2020 ([https://www.youtube.com/watch?v=-oCqhfiGbfU&ab\\_channel=Wylsacom](https://www.youtube.com/watch?v=-oCqhfiGbfU&ab_channel=Wylsacom)) на канале Wylsacom (<https://www.youtube.com/user/Wylsacom>). С помощью сервиса <https://popsters.ru/app/dashboard>




Рис. 10: Комментарии

## Комментарии

136



Рис. 11: Комментарии



 Wylsacom



Рис. 12: Комментарии

#### 1.4 Моделирование показательного распределения:

Пусть дана функция распределения случайной величины  $\xi$  -  $F_\xi(x)$ , причем  $F_\xi(x)$  - непрерывна и монотонно возрастает. Тогда  $F_\xi^{-1}(y)$  существует и является обратной функцией, определенной на отрезке  $[0,1]$ . Пусть  $\eta$  будет являться случайной величиной с равномерным распределением, где  $f_\eta(x) \in [0,1]$ . Тогда:

$$P(\eta_i \leq F_\xi(x)) = P(F_\xi^{-1}(\eta_i) \leq x) = P(x_i \leq x) = F_\xi(x)$$

Из этого следует, что при помощи случайной величины  $\eta$  генерируется случайная величина, которая имеет распределение  $F_\xi(x)$ . Тогда, при условии, что мы знаем явный вид  $F_\xi^{-1}(y)$ , то получается определенный алгоритм моделирования величины  $\xi$ .

Первый шаг: генерируется следующее значение  $\eta_i$

Второй шаг: подставляем полученное значение в обратную функцию  $F_\xi^{-1}(y)$

Третий шаг: получаем очередное значение величины  $X$

Найдем обратную функцию к  $F_\xi(x) = 1 - e^{-\lambda x}$  в области  $x \geq 0$ . И реализуем алгоритм для показательного распределения:

$$\begin{aligned} F_\xi(x) &= 1 - e^{-(\lambda)x} \\ y &= 1 - e^{\lambda x} \\ X &= \frac{\ln(1-y)}{-\lambda} \end{aligned}$$

```

import random
import matplotlib.pyplot as plt
import math
import numpy as np
from statsmodels.distributions.empirical_distribution import ECDF
from scipy.stats import expon

def Pocaz():
    lx=[]
    ly=[]

    yi = lambda x: 1-math.e**(-x)
    xi = np.linspace(0, 9,100)
    def modal(x):
        return(-math.log(1-x)/1)
    for i in range(500):
        X=random.random()#сохранение значений
        Y=modal(X)
        lx.append(X)
        ly.append(Y)
    ecdfy=ECDF(ly)
    #print(ecdfy.x,ecdfy.y,sep='\n')
    plt.plot(ecdfy.x,ecdfy.y,'ro')
    plt.plot(xi,yi(xi))
    plt.show()

Pocaz()

```

Рис. 13: Код




Рис. 14: График

## 2. Домашнее задание. Основные понятия математической статистики

### 2.1. Равномерное дискретное распределение

#### 2.1.1. Моделирование выбранной случайной величины

На основе моделирования дискретного равномерного распределения, описанного в домашнем задании 1, создаем функцию, с помощью которой генерируем по 5 выборок каждого объема. Для примера напечатаны сгенерированные выборки объема  $n=5$  и  $n=10$ .

Output:

```
-n=5  
[5, 3, 3, 3, 4]  
[4, 7, 7, 1, 2]  
[6, 5, 6, 1, 5]  
[3, 5, 5, 1, 5]  
[2, 7, 7, 7, 6]
```

```
-n=10  
[4, 7, 5, 1, 4, 4, 7, 1, 4, 3]  
[4, 6, 4, 4, 7, 6, 7, 2, 5, 2]  
[7, 6, 7, 6, 4, 6, 5, 4, 2, 4]  
[2, 4, 2, 1, 2, 2, 6, 2, 1, 2]  
[1, 5, 3, 1, 7, 1, 4, 4, 2, 3]
```

Код, с помощью которого генерируется по 5 выборок каждого объема  $n=5, 10, 100, 1000, 10000$ . Итого 25 различных выборок для выбранного дискретного распределения.

Code:

```
import numpy  
import random  
from matplotlib import pyplot, axes  
  
def generate(N=8,n=5):  
    lx=[]  
    dic = {}  
    for i in range(N):  
        dic[i+1]=(i/N,(i+1)/N)  
    for i in range(n):  
        rand_number = random.random()  
        for i in dic:  
            if dic[i][0] <= rand_number < dic[i][1]:  
                x = i  
        lx.append(x)  
    return(lx)  
generate()
```

Рис. 15: Код выборок  $n=5$

```

import numpy
import random
from matplotlib import pyplot, axes

def generate(N=8,n=10):
    lx=[]
    dic = {}
    for i in range(N):
        dic[i+1]=(i/N,(i+1)/N)
    for i in range(n):
        rand_number = random.random()
        for i in dic:
            if dic[i][0] <= rand_number < dic[i][1]:
                x = i
        lx.append(x)
    return(lx)
generate()

```

Рис. 16: Код выборок n=10

### 2.1.2. Построение эмпирической функции распределения

Для каждой выборки строим эмпирическую функцию распределения. В отчете продемонстрировано построение эмпирической функции распределения для выборок размера 5. На одном графике отображены эмпирические функции распределения для 5 выборок данного объема и график функции распределения.

Code:

```

def ecdf(sample):
    ly=[]
    for i in range(7):
        ly.append(sample.count(i+1)/len(sample))
    ly = list(filter(lambda a: a != 0, ly))
    ly.insert(0,0)
    for i in range(1,len(ly)):
        ly[i]= ly[i]+ly[i-1]
    return(ly)

print(ecdf(samples_list[0]))
def gen_ecdf(samples_list):
    ecdf_list = []
    for i in range(25):
        ecdfx = list(set(samples_list[i]))
        ecdfx.insert(0,numpy.NINF)
        ecdfy = ecdf(samples_list[i])
        ecdf_list.append((ecdfx, ecdfy))
    return(ecdf_list)

ecdf_list = gen_ecdf(samples_list)
print(ecdf_list[0])
for i in range(5):
    sample_ecdf = ecdf_list[i]
    print('ECDF F(x) for sample', i+1, ':')
    for k in range(len(sample_ecdf[0])-1):
        print(sample_ecdf[1][k], ' ', sample_ecdf[0][k], '< x <=', sample_ecdf[0][k+1])
    print(sample_ecdf[1][-1], ' ', 'x > ', sample_ecdf[0][-1], '\n')

```

Рис. 17: Код

Output:

ECDF F(x) for sample 1 :

0 , -inf < x <= 3  
 0.6 , 3 < x <= 4  
 0.8 , 4 < x <= 5  
 1.0 , x > 5

ECDF F(x) for sample 1 :

0 , -inf < x <= 3  
 0.6 , 3 < x <= 4  
 0.8 , 4 < x <= 5  
 1.0 , x > 5

ECDF  $F(x)$  for sample 2 :

0 ,  $-\infty < x \leq 1$   
0.2 ,  $1 < x \leq 2$   
0.4 ,  $2 < x \leq 4$   
0.6000000000000001 ,  $4 < x \leq 7$   
1.0 ,  $x > 7$

ECDF  $F(x)$  for sample 3 :

0 ,  $-\infty < x \leq 1$   
0.2 ,  $1 < x \leq 5$   
0.6000000000000001 ,  $5 < x \leq 6$   
1.0 ,  $x > 6$

ECDF  $F(x)$  for sample 4 :

0 ,  $-\infty < x \leq 1$   
0.2 ,  $1 < x \leq 3$   
0.4 ,  $3 < x \leq 5$   
1.0 ,  $x > 5$

ECDF  $F(x)$  for sample 5 :

0 ,  $-\infty < x \leq 2$   
0.2 ,  $2 < x \leq 6$   
0.4 ,  $6 < x \leq 7$   
1.0 ,  $x > 7$

Code:

```
for k in range(0,5):
    sample_ecdf = ecdf_list[k]
    print(sample_ecdf)
    color = colors[k%5]
    pyplot.plot([0,sample_ecdf[0][1]],[0,0], c=color, alpha=0.7, linewidth=4)
    for i in range(1,len(sample_ecdf[0])-1):
        pyplot.plot([sample_ecdf[0][i],sample_ecdf[0][i+1]],[sample_ecdf[1][i],sample_ecdf[1][i]],
                    c=color, alpha=0.7,linewidth=4)
    pyplot.plot([sample_ecdf[0][-1], sample_ecdf[0][-1]+1],[1,1],c=color, alpha=0.7, linewidth=4)
pyplot.xlabel('numbers')
pyplot.ylabel('probability')
pyplot.title('ECDF')
x = numpy.linspace(1,7,100)
pyplot.plot(x, y:=numpy.floor(x)/7, 'b')
pyplot.plot(numpy.linspace(0,1,100), y:=x*0, 'b')
pyplot.plot(numpy.linspace(7,8,100), y:=(0*x)+1, 'b')
pyplot.show()
```

Рис. 18: Код

Output:

-n=5




Рис. 19: n=5

-n=10

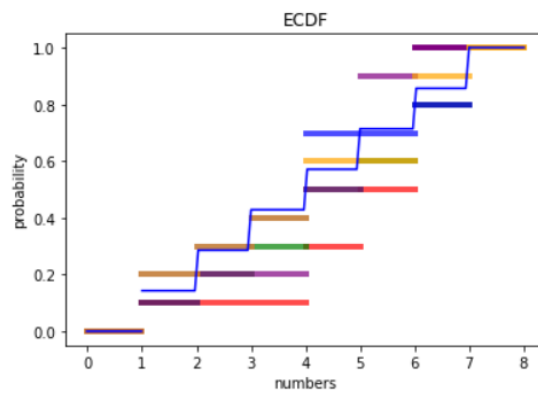


Рис. 20: n=10



-n=100




Рис. 21: n=100

-n=1000




Рис. 22: n=1000

-n=10000

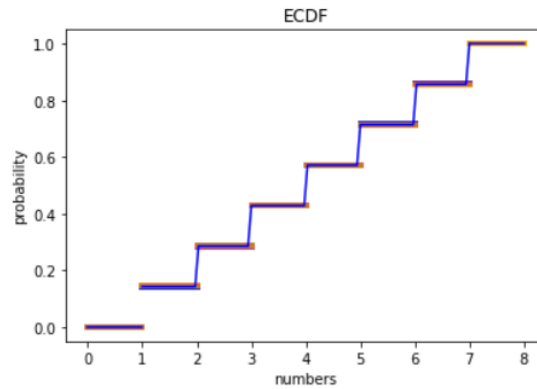


Рис. 23: n=10000

Существует учиненный закон больших чисел, в котором эмпирическая функция почти наверное к теоретической функции:  $\hat{F}(x) \rightarrow F(x)$  почти наверное при  $n \rightarrow \infty$ . По данным, которые представлены на графике видно, что совпадение графика эмпирической функции с графиком теоретической функции распределения зависит от объема выборки  $n$ . Чем оно больше, тем больше совпадают графики.

Для каждого  $n$  найдем максимальную точную верхнюю границу разности каждой пары эмпирических функций распределения среди всех возможных пар. Для Каждой пары рассмотрим определенное количество вариантов, равное  $C_5^2$

Точная верхняя граница разности - это наибольшее число разности значений  $ECDF$  функций при одинаковых аргументах. Данное число можно вычислить при помощи кода представленного ниже.

Code:

```
diff_list=[]
for i in range(4):
    for k in range(i+1,10):
        sample1=ecdf_list[i+5*n]
        sample2=ecdf_list[k+5*n]
        for j in range(1,len(sample1[0])-1):
            pair1 = [sample1[0][j],sample1[0][j+1]]
            for p in range(1,len(sample2[0])-1):
                pair2=[sample2[0][p],sample2[0][p+1]]
                if ((pair2[0]<=pair1[0] and pair2[1] >= pair1[0]) or (pair2[0]<=pair1[1] and pair2[1]>=pair1[1])):
                    diff_list.append(abs(sample1[1][j]-sample2[1][p]))
print(max(diff_list))
```

Рис. 24: Код

Output:

n=5-0.60000000000000001  
n=10-0.60000000000000001  
n=100-0.33  
n=1000-0.16599999999999998  
n=100000-0.05281999999999994

Точные верхнии границы разности будут уменьшаться при приближении эмпирической функции к теоретической с ростом  $n$ .

### 2.1.3. Построение вариационного ряда выборки

Вариационный ряд - набор элементов  $X_1, \dots, X_n$ , упорядоченный по возрастанию. Ниже представлен код, с помощью которого строятся вариационные ряды для каждой сгенерированной выборки. В отчете представлены вариационные ряды для выборок объема  $n = 5$ ,  $n = 10$ .

Code:

```
var_list = []  
  
for sample in samples_list:  
    var_sample = sorted(sample)  
    var_list.append(var_sample)  
  
for i in range(10):  
    print(var_list[i])
```

Рис. 25: Код

Output:

-n = 5 :

[3, 3, 3, 4, 5]  
[1, 2, 4, 7, 7]  
[1, 5, 5, 6, 6]  
[1, 3, 5, 5, 5]  
[2, 6, 7, 7, 7]

-n = 10 :

[1, 1, 3, 4, 4, 4, 4, 5, 7, 7]  
[2, 2, 4, 4, 4, 5, 6, 6, 7, 7]  
[2, 4, 4, 4, 5, 6, 6, 6, 7, 7]  
[1, 1, 2, 2, 2, 2, 2, 2, 4, 6]  
[1, 1, 1, 2, 3, 3, 4, 4, 5, 7]

$\alpha$ -квантиль случайной величины  $\xi$  с функцией распределения  $F_\xi(x) = P(\xi < x)$ -любое число  $x_\alpha$ , которое удовлетворяет двум условиям:

$$-F_\xi(x_\alpha) \leq \alpha$$

$$-F_\xi(x_\alpha + 0) \geq \alpha$$

Code:

```
quantile_list=[0.1,0.5,0.7]
for element in ecdf_list:
    for quantile in quantile_list:
        if quantile in element[1]:
            q = element[1].index(quantile)
            print('q=', quantile, 'in', len(element[1])-1, 'x=', element[0][q+1])
```

Рис. 26:  $n=10000$

Output:

q= 0.5 in 5 x= 5  
q= 0.1 in 5 x= 4  
q= 0.5 in 5 x= 6  
q= 0.1 in 7 x= 2

При больших э.ф.р. стремятся к теоритической функции распределения, эмпирические квантили так же стремятся к теоритическим по определению.

#### 2.1.4. Построение гистограммы и полигона частот

Строим полигоны частот и гистограммы частот, на одном графике размещая функции 5 выборок данного объема и теоретическую функцию.

При увеличении  $n$  полигоны частот и гистограммы стремятся к теоретической функции плотности. Как можно наблюдать ниже на графиках.

- $n=5$




Рис. 27:  $n=5$

-n=10

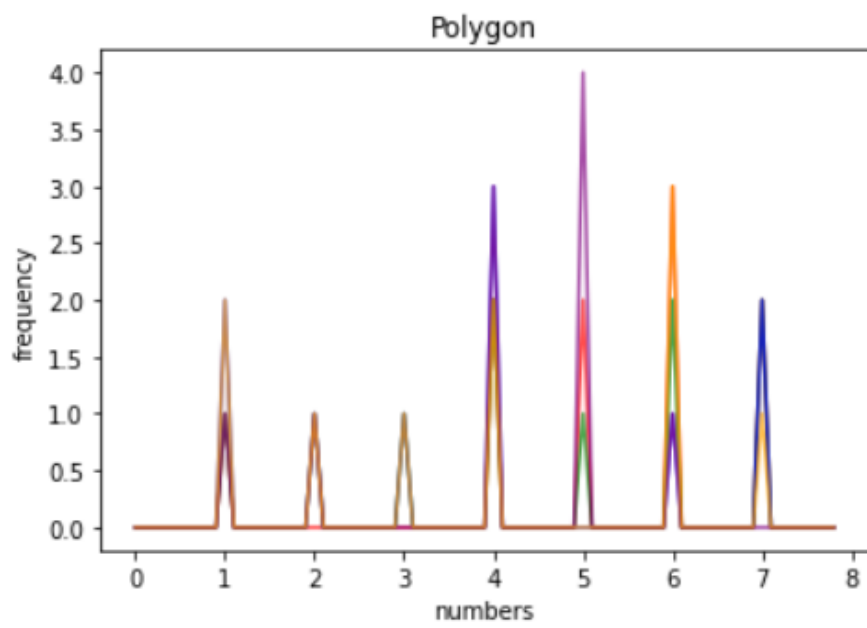


Рис. 28: n=10

-n=100




Рис. 29: n=100

-n=1000




Рис. 30:  $n=1000$

-n=10000  
-n=5

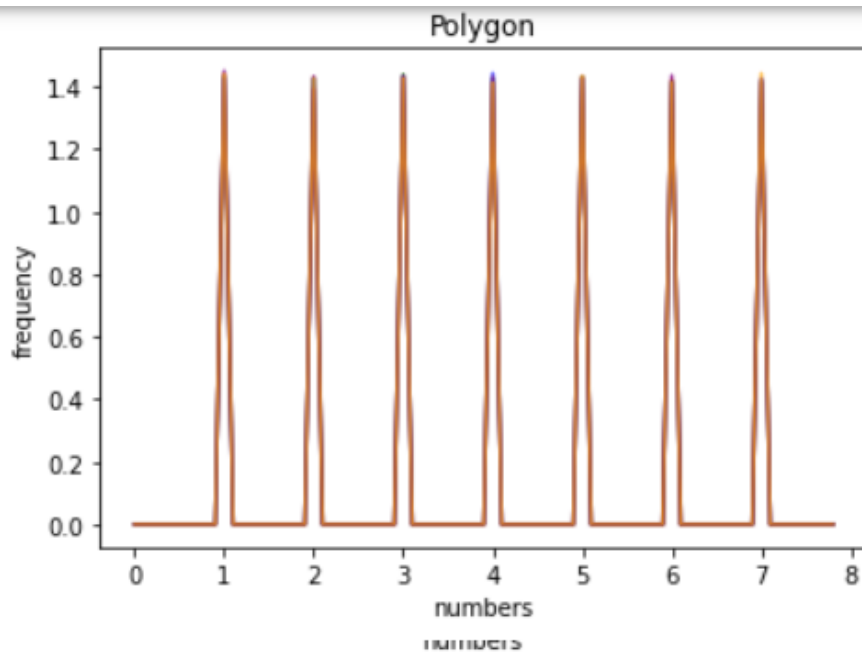


Рис. 31:  $n=10000$




Рис. 32:  $n=5$

- $n=10$




Рис. 33:  $n=10$

- $n=100$




Рис. 34:  $n=100$

- $n=1000$




Рис. 35:  $n=1000$



-n=10000




Рис. 36: n=10000

Code:

```
for i in range(0,5):
    color=colors[i%5]
    counts, bins = numpy.histogram(samples_list[i], bins=numpy.arange(0,8,0.1), density=True)
    pyplot.plot(bins[:-1], counts, color=color, alpha=0.7)
pyplot.xlabel('numbers')
pyplot.ylabel('frequency')
pyplot.title('Polygon')
pyplot.show()
```

Рис. 37: Код

```
for i in range(0,5):
    color=colors[i%5]
    counts, bins = numpy.histogram(samples_list[i], bins=numpy.arange(0,8,0.1), density=True)
    pyplot.plot(bins[:-1], counts, color=color, alpha=0.7)
pyplot.xlabel('numbers')
pyplot.ylabel('frequency')
pyplot.title('Polygon')
pyplot.show()
```

Рис. 38: Код

## 2.2. Экспоненциальное распределение

### 2.2.1. Моделирование выбранной случайной величины

На основе моделирования дискретного равномерного распределения, описанного в домашнем задании 1, создаем функцию, с помощью которой генерируем по 5 выборок каждого объема. Для примера напечатаны сгенерированные выборки объема  $n=5$  и  $n=10$ .

Output:

-n=5

[0.16434301457281045, 0.6172450408927916, 0.6883199816464598, 2.7371544197817026, 5.673749863108269]  
[0.04666232802146302, 0.426946266051896, 0.5528180465210837, 0.8334028818704013, 1.4603498342455614]  
[0.2829500277473982, 0.2847671919813394, 0.7145741624776435, 0.8140387406630023, 1.374262248737471]  
[0.7405392649830047, 0.9704575012125974, 1.0476765340252499, 1.19687704861772, 1.5401575489450705]  
[0.602507792380593, 0.7592083198125391, 1.3862009444108174, 1.5361005698043353, 2.4003764038702555]

-n=10

[[0.017400241396125234, 0.24743305378966501, 0.30518229114622886, 0.38623221599747204, 0.7108156828644356, 0.7650492552734278, 1.1704413373311817, 1.1960967845087855, 1.7374010777243183, 2.710884863378893]  
[0.2018400497477813, 0.3344536166156225, 0.36029107196831084, 0.473291146028304, 0.7962614045780094, 0.8546230897791269, 0.934767835867592, 1.3675060041415124, 1.7079823954725326, 2.468894921619211]  
[0.05746105376568163, 0.06209887456824994, 0.4727269575729011, 0.4742272339308097, 0.691099822405431, 0.8582509004218759, 1.159334248258738, 1.5271811749149165, 1.64485827684547, 2.1699870785164004]  
[0.033281864405029817, 0.06841803989290686, 0.5523037426270578, 1.2267826029047861, 1.3259955356400717, 1.3343707850394242, 1.4194334218672617, 1.5112018846427622, 2.089906092898997, 2.409332449393737]  
[0.13312206471118385, 0.23808417916430138, 0.2916973253887163, 0.31876171786448915, 0.8331820947219716, 1.0959642763443254, 1.3737520761689035, 2.3992930609655176, 2.600199328472886, 3.713027024780754]

Код, с помощью которого генерируется по 5 выборок каждого объема n=5, 10, 100, 1000, 10000. Итого 25 различных выборок для выбранного дискретного распределения.

Code:

```
30 def gen_samples():
31     volume_list = [5,10,100,1000,10000]
32     samples_list = []
33     for v in volume_list:
34         for i in range(5):
35             samples_list.append(generate(n=v))
36
37
38     return(samples_list)
39
40 samples_list = gen_samples()
41
42 for i in range(10):
43     print(samples_list[i])
```

Рис. 39: Код выборок n=5

```

30 def gen_samples():
31     volume_list = [5,10,100,1000,100000]
32     samples_list = []
33     for v in volume_list:
34         for i in range(5):
35             samples_list.append(generate(n=v))
36
37
38     return(samples_list)
39
40 samples_list = gen_samples()
41
42 for i in range(10):
43     print(samples_list[i])

```

Рис. 40: Код выборок n=10

### 2.2.2. Построение эмпирической функции распределения

Для каждой выборки строим эмпирическую функцию распределения. В отчете продемонстрировано построение эмпирической функции распределения для выборок размера 5. На одном графике отображены эмпирические функции распределения для 5 выборок данного объема и график функции распределения.

Code:

```

45 def gen_ecdf(samples_list):
46     ecdf_list = []
47     for sample in range(25):
48         ecdf = ECDF(samples_list[sample])
49         ecdf_list.append((ecdf.x, ecdf.y))
50     return(ecdf_list)
51
52 ecdf_list = gen_ecdf(samples_list)
53
54 for i in range(5):
55     sample_ecdf = ecdf_list[i]
56     print('ECDF F(x) for sample', i+1, ':')
57     for k in range(len(sample_ecdf[0])-1):
58         print(sample_ecdf[1][k], ' ', sample_ecdf[0][k], '< x <=', sample_ecdf[0][k+1])
59     print(sample_ecdf[1][-1], ' ', sample_ecdf[0][-1], '\n')

```

Рис. 41: Код

Output:

ECDF F(x) for sample 1 :

```

0.0 , -inf < x <= 0.16434301457281045
0.2 , 0.16434301457281045 < x <= 0.6172450408927916
0.4 , 0.6172450408927916 < x <= 0.6883199816464598
0.6000000000000001 , 0.6883199816464598 < x <= 2.7371544197817026
0.8 , 2.7371544197817026 < x <= 5.673749863108269
1.0 , x > 5.673749863108269

```

ECDF F(x) for sample 2 :

```

0.0 , -inf < x <= 0.04666232802146302
0.2 , 0.04666232802146302 < x <= 0.426946266051896
0.4 , 0.426946266051896 < x <= 0.5528180465210837
0.6000000000000001 , 0.5528180465210837 < x <= 0.8334028818704013
0.8 , 0.8334028818704013 < x <= 1.4603498342455614
1.0 , x > 1.4603498342455614

```

ECDF F(x) for sample 3 :

```

0.0 , -inf < x <= 0.2829500277473982
0.2 , 0.2829500277473982 < x <= 0.2847671919813394

```

0.4 , 0.2847671919813394 < x <= 0.7145741624776435  
 0.6000000000000001 , 0.7145741624776435 < x <= 0.8140387406630023  
 0.8 , 0.8140387406630023 < x <= 1.374262248737471  
 1.0 , x > 1.374262248737471

ECDF F(x) for sample 4 :

0.0 , -inf < x <= 0.7405392649830047  
 0.2 , 0.7405392649830047 < x <= 0.9704575012125974  
 0.4 , 0.9704575012125974 < x <= 1.0476765340252499  
 0.6000000000000001 , 1.0476765340252499 < x <= 1.19687704861772  
 0.8 , 1.19687704861772 < x <= 1.5401575489450705  
 1.0 , x > 1.5401575489450705

ECDF F(x) for sample 5 :

0.0 , -inf < x <= 0.602507792380593  
 0.2 , 0.602507792380593 < x <= 0.7592083198125391  
 0.4 , 0.7592083198125391 < x <= 1.3862009444108174  
 0.6000000000000001 , 1.3862009444108174 < x <= 1.5361005698043353  
 0.8 , 1.5361005698043353 < x <= 2.4003764038702555  
 1.0 , x > 2.4003764038702555

Code:

```
61 colors = ['red', 'green', 'blue', 'purple', 'orange']
62
63 for k in range(0,5):
64     sample_ecdf = ecdf_list[k]
65     print(sample_ecdf)
66     color = colors[k%5]
67     pyplot.plot([0,sample_ecdf[0][1]], [0,0], c=color, alpha=0.7, linewidth=4)
68     for i in range(1,len(sample_ecdf[0])-1):
69         pyplot.plot([sample_ecdf[0][i],sample_ecdf[0][i+1]], [sample_ecdf[1][i],sample_ecdf[1][i]], c=color, alpha=0.7, linewidth=4)
70     pyplot.plot([sample_ecdf[0][-1], sample_ecdf[0][-1]+1], [1,1], c=color, alpha=0.7, linewidth=4)
71
72 x = numpy.linspace(0,4,100)
73 pyplot.plot(x, y:=1-numpy.exp(-1*x), 'b')
74 pyplot.show()
75 (x, y:=numpy.exp(-1*x), 'b')
76 pyplot.show()
```

Рис. 42: Код

Output:

-n=5




Рис. 43:  $n=5$

-n=10




Рис. 44:  $n=10$

-n=100




Рис. 45: n=100

-n=1000




Рис. 46: n=1000

-n=10000




Рис. 47: n=10000

Существует учиненный закон больших чисел, в котором эмпирическая функция почти наверное к теоретической функции:  $\hat{F}(x) \rightarrow F(x)$  почти наверное при  $n \rightarrow \infty$ . По данным, которые представлены на графике видно, что совпадение графика эмпирической функции с графиком теоретической функции распределения зависит от объема выборки  $n$ . Чем оно больше, тем больше совпадают графики.

Для каждого  $n$  найдем максимальную точную верхнюю границу разности каждой пары эмпирических функций распределения среди всех возможных пар. Для Каждой пары рассмотрим определенное количество вариантов, равное  $C_5^2$

Точная верхняя граница разности - это наибольшее число разности значений  $ECDF$  функций при одинаковых аргументах. Данное число можно вычислить при помощи кода представленного ниже.

Code:

```
159 diff_list=[]
160 for i in range(4):
161     for k in range(i+1,10):
162         sample1=ecdf_list[i+5*n]
163         sample2=ecdf_list[k+5*n]
164         for j in range(1,len(sample1[0])-1):
165             pair1 = [sample1[0][j],sample1[0][j+1]]
166             for p in range(1,len(sample2[0])-1):
167                 pair2=[sample2[0][p],sample2[0][p+1]]
168                 if ((pair2[0]<=pair1[0] and pair2[1] >= pair1[0]) or (pair2[0]<=pair1[1] and pair2[1]>=pair1[1])):
169                     diff_list.append(abs(sample1[1][j]-sample2[1][p]))
170 print(max(diff_list))
171
172 var_list = []
```

Рис. 48: Код

Output:

n=5-0.60000000000000001  
n=10-0.60000000000000001  
n=100-0.33  
n=1000-0.16599999999999998  
n=10000-0.14641999999999994

Точные верхнии границы разности будут уменьшаться при приближении эмпирической функции к теоретической с ростом  $n$ .

### 2.2.3. Построение вариационного ряда выборки

Вариационный ряд - набор элементов  $X_1, \dots, X_n$ , упорядоченный по возрастанию. Ниже представлен код, с помощью которого строятся вариационные ряды для каждой сгенерированной выборки. В отчете представлены вариационные ряды для выборок объема  $n = 5$ ,  $n = 10$ .

Code:

```
172 var_list = []
173
174 for sample in samples_list:
175     var_sample = sorted(sample)
176     var_list.append(var_sample)
177
178 for i in range(10):
179     print(var_list[i])
180
```

Рис. 49: n=10000

Output:

-n = 5 :

[3, 3, 3, 4, 5]  
[1, 2, 4, 7, 7]  
[1, 5, 5, 6, 6]  
[1, 3, 5, 5, 5]  
[2, 6, 7, 7, 7]

-n = 10 :

[1, 1, 3, 4, 4, 4, 4, 5, 7, 7]  
[2, 2, 4, 4, 4, 5, 6, 6, 7, 7]  
[2, 4, 4, 4, 5, 6, 6, 6, 7, 7]  
[1, 1, 2, 2, 2, 2, 2, 2, 4, 6]  
[1, 1, 1, 2, 3, 3, 4, 4, 5, 7]

$\alpha$ -квантиль случайной величины  $\xi$  с функцией распределения  $F_\xi(x) = P(\xi < x)$ -любое число  $x_\alpha$ , которое удовлетворяет двум условиям:

$$F_\xi(x_\alpha) \leq \alpha$$
$$F_\xi(x_\alpha + 0) \geq \alpha$$



Code:

```
quantile_list=[0.1,0.5,0.7]
for element in ecdf_list:
    for quantile in quantile_list:
        if quantile in element[1]:
            q = element[1].index(quantile)
            print('q=', quantile, 'in', len(element[1])-1, 'x=', element[0][q+1])
```

**Рис. 50:** n=10000

Output:

q= 0.1 in 10 x= 0.6413320745799311  
q= 0.5 in 10 x= 0.910640008327763  
q= 0.1 in 10 x= 0.12399528221711266  
q= 0.5 in 10 x= 0.7906900254239998  
q= 0.1 in 10 x= 0.3620208678055566  
q= 0.5 in 10 x= 0.812727627733623  
q= 0.1 in 10 x= 0.18279315356500137  
q= 0.5 in 10 x= 1.1445950153100095  
q= 0.1 in 10 x= 0.11689336921577874  
q= 0.5 in 10 x= 1.3870231080405808  
q= 0.5 in 100 x= 0.7934820621085901  
q= 0.5 in 100 x= 0.793073541539919  
q= 0.5 in 100 x= 0.8403326253990359  
q= 0.5 in 100 x= 0.9128728846620282  
q= 0.5 in 100 x= 0.6371726007486764  
q= 0.1 in 1000 x= 0.10843256891167612  
q= 0.5 in 1000 x= 0.7037936174682455  
q= 0.1 in 1000 x= 0.10181855264122328  
q= 0.5 in 1000 x= 0.6612883835095232  
q= 0.1 in 1000 x= 0.09519690655230126  
q= 0.5 in 1000 x= 0.6150171893581541  
q= 0.1 in 1000 x= 0.1104187302789945  
q= 0.5 in 1000 x= 0.7101891924275118  
q= 0.1 in 1000 x= 0.10293627298446764  
q= 0.5 in 1000 x= 0.6644350911354294  
q= 0.1 in 100000 x= 0.10616135390540682  
q= 0.5 in 100000 x= 0.6956843876851393  
q= 0.1 in 100000 x= 0.10417649816429929  
q= 0.5 in 100000 x= 0.6912307711709078  
q= 0.1 in 100000 x= 0.10433782019034865  
q= 0.5 in 100000 x= 0.69497424308664  
q= 0.1 in 100000 x= 0.10565314554016611  
q= 0.5 in 100000 x= 0.694595466157049  
q= 0.1 in 100000 x= 0.1054678901206238  
q= 0.5 in 100000 x= 0.6907414403728113

#### 2.2.4. Построение гистограммы и полигона частот

Строим полигоны частот и гистограммы частот, на одном графике размещая функции 5 выборок данного объема и теоретическую функцию.

При увеличении  $n$  полигоны частот и гистограммы стремятся к теоретической функции плотности. Как можно наблюдать ниже на графиках.

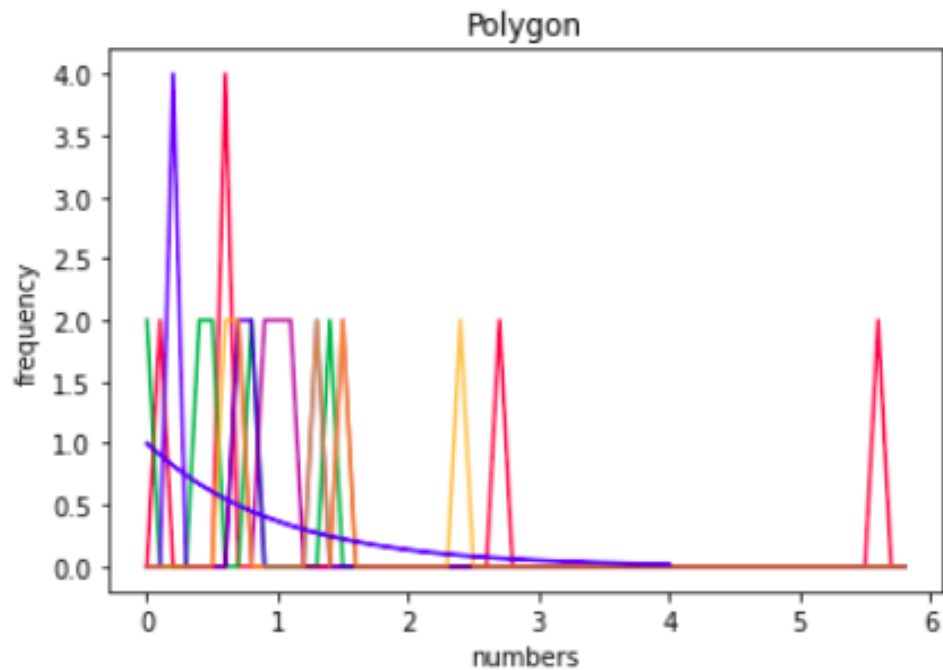


Рис. 51:  $n=5$




Рис. 52:  $n=10$




Рис. 53:  $n=100$




Рис. 54:  $n=1000$

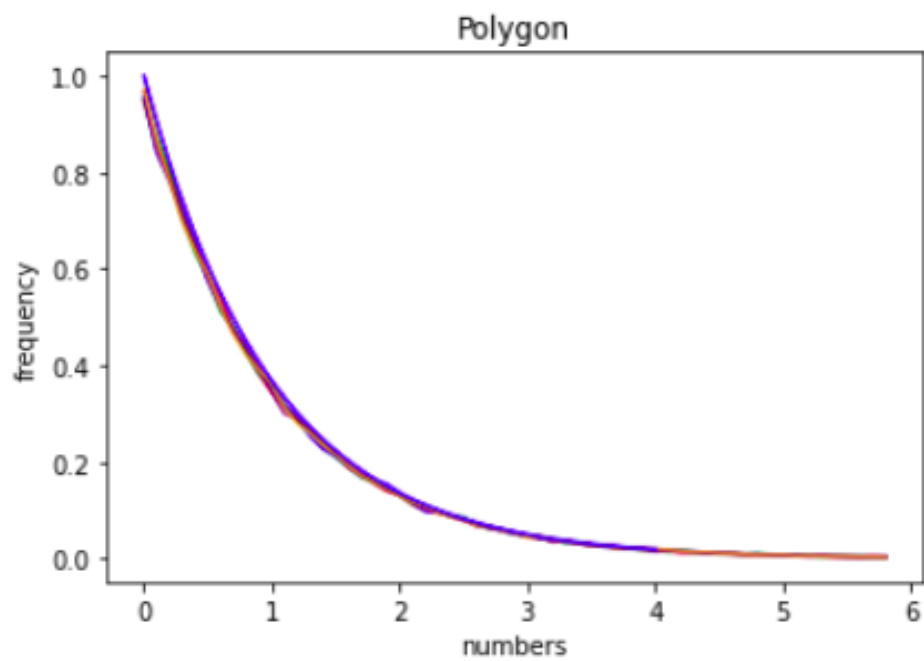


Рис. 55:  $n=10000$




Рис. 56:  $n=5$




Рис. 57:  $n=10$




Рис. 58:  $n=100$




Рис. 59:  $n=1000$




Рис. 60:  $n=10000$

Code:

```
200 colors = ['red', 'green', 'blue', 'purple', 'orange']
201
202 for i in range(0,5):
203     color = colors[i%5]
204     sample = samples_list[i]
205     pyplot.hist(sample,bins=10, color=color, alpha=0.7)
206 pyplot.xlabel('numbers')
207 pyplot.ylabel('frequency')
208 pyplot.title('Histogram')
209 pyplot.show()
```

Рис. 61: Код

```

164 for i in range(10,15):
165     color=colors[i%5]
166     counts, bins = numpy.histogram(samples_list[i], bins=numpy.arange(0,6,0.1), density=True)
167     pyplot.plot(bins[:-1], counts, color=color, alpha=0.7)
168
169     x = numpy.linspace(0,4,100)
170     pyplot.xlabel('numbers')
171     pyplot.ylabel('frequency')
172     pyplot.title('Polygon')
173     pyplot.plot(x, y:=numpy.exp(-1*x), 'b')
174     pyplot.show()

```

Рис. 62: Код

### 3. Домашнее задание. Оценки

#### 3.1. Дискретное равномерное распределение

##### 3.1.1. Нахождение выборочного среднего и выборочной дисперсии

Наиболее важными характеристиками случайной величины  $\xi$  являются ее моменты  $= E\xi^k$ , а также центральные моменты  $\mu^k = E(\xi - \alpha_1)^k$  (когда они существуют). Их статистическими аналогами, вычисляемыми по соответствующей выборке  $X = (X_1, \dots, X_n)$ , являются выборочные моменты соответственно обычные:

$$\hat{\alpha}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

и центральные:

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\alpha}_1)^k$$

$\hat{\alpha}_1$  (принято обозначать как  $\bar{X}$ ) называется выборочным средним,  $\hat{\mu}_2$  - выборочной дисперсией. Таким образом, выборочное среднее и выборочная дисперсия являются статистическими аналогами теоретических среднего (математического ожидания)  $E\xi$  и дисперсии  $D\xi$ , когда они существуют.

Для каждой выработанной ранее выборки найдем выборочное среднее и выборочную дисперсию.

Приведем только выборки размера 5 и 10, для проверки правильности вычислений:

n=5

[4, 3, 7, 2, 2]  
 [2, 1, 7, 2, 6]  
 [2, 2, 5, 1, 6]  
 [5, 7, 5, 6, 1]  
 [4, 2, 7, 6, 1]

n=10

[5, 4, 3, 5, 4, 1, 1, 7, 6, 1]  
 [2, 2, 6, 4, 6, 6, 7, 1, 3, 1]  
 [3, 4, 1, 2, 1, 4, 5, 7, 5, 4]  
 [2, 6, 2, 6, 4, 3, 2, 4, 3, 7]  
 [5, 3, 7, 4, 3, 1, 4, 4, 6, 6]



Создаем функции для вычисления выборочных среднего и дисперсии и применяем их к сгенерированным выборкам распределения.

Выборочное среднее:

```
95 for i in range(15,20):
96     sum_el = 0
97     for item in var_list[i]:
98         sum_el = sum_el+item
99     raz_var = len(var_list[i])
100    it_sr = sum_el/raz_var
101    srvr_list.append(it_sr)
102    print("Выборочное среднее - ", it_sr)
```

Рис. 63: Код

n=5

Выборочное среднее - 3.6  
Выборочное среднее - 3.6  
Выборочное среднее - 3.2  
Выборочное среднее - 4.8  
Выборочное среднее - 4.0

n=10

Выборочное среднее - 3.7  
Выборочное среднее - 3.8  
Выборочное среднее - 3.6  
Выборочное среднее - 3.9  
Выборочное среднее - 4.3

n=100

Выборочное среднее - 3.69  
Выборочное среднее - 4.27  
Выборочное среднее - 3.95  
Выборочное среднее - 4.03  
Выборочное среднее - 4.43

n=1000

Выборочное среднее - 3.959  
Выборочное среднее - 3.95  
Выборочное среднее - 4.016  
Выборочное среднее - 3.993  
Выборочное среднее - 4.014

n=10000

Выборочное среднее - 4.00641  
Выборочное среднее - 4.00459  
Выборочное среднее - 3.99936  
Выборочное среднее - 4.00149

## Исправлено:

---

С помощью формул выведенных в первом домашнем задании посчитаем математическое ожидание для N=8:

$$M\xi = \frac{N+1}{2} = \frac{9}{2} = 4,5$$

Выборочное среднее стремится к истинному значению математического ожидания при увеличении объема выборки. И это обусловлено свойством состоятельности нашей оценки, которое в свою очередь обусловлено законом больших чисел. Покажем это при помощи закона больших чисел Хинчина:

$$\frac{\xi_1 + \xi_2 + \dots + \xi_{n-1} + \xi_n}{n} \xrightarrow{P} M\xi$$

Если существует  $M|\xi_1|$  тогда:

$$\overline{X_n} \xrightarrow{P} M\xi, n \rightarrow \infty$$

Получается, что по закону больших чисел Хинчина оценка является состоятельной. Выборочное среднее обладает свойством несмещенности. Тогда покажем, что математическое ожидание от оценки будет равно истинному математическому ожиданию:

$$M\overline{X} = M\left(\frac{1}{n} \sum_{i=1}^n M(X_i)\right) = \frac{1}{n} \cdot n \cdot M\xi = M\xi$$

Мы показали, что эта оценка является несмещенной.

---

Выборочная дисперсия вычисляется с помощью кода представленного ниже:

```
191 for i in range(20,25):
192     sum_el = 0
193     sum_el_dic = 0
194     for item in var_list[i]:
195         sum_el = sum_el+item
196     for item in var_list[i]:
197         sum_el_dic = sum_el_dic+item*item
198     raz_var = len(var_list[i])
199     it_sr = sum_el/raz_var
200     it_sr_dic = sum_el_dic/raz_var-it_sr*it_sr
201     print("Выборочная дисперсия - ", it_sr_dic)
202
```

Рис. 64: Код

n=5

Выборочная дисперсия - 3.4399999999999977

Выборочная дисперсия - 5.84

Выборочная дисперсия - 3.7599999999999998

Выборочная дисперсия - 4.16

Выборочная дисперсия - 5.1999999999999999

n=10

Выборочная дисперсия - 4.209999999999997  
Выборочная дисперсия - 4.76  
Выборочная дисперсия - 3.2399999999999984  
Выборочная дисперсия - 3.0900000000000016  
Выборочная дисперсия - 2.8100000000000023

n=100

Выборочная дисперсия - 4.0139  
Выборочная дисперсия - 3.9771000000000036  
Выборочная дисперсия - 4.407500000000001  
Выборочная дисперсия - 4.129099999999976  
Выборочная дисперсия - 3.7051000000000016

n=1000

Выборочная дисперсия - 3.8253189999999986  
Выборочная дисперсия - 3.707499999999998  
Выборочная дисперсия - 4.015743999999998  
Выборочная дисперсия - 4.200951  
Выборочная дисперсия - 4.077804

n=10000

Выборочная дисперсия - 4.009068911900002  
Выборочная дисперсия - 4.002488931899997  
Выборочная дисперсия - 3.993259590400003  
Выборочная дисперсия - 4.020787779899997  
Выборочная дисперсия - 4.0198900144

### Исправлено:

---

Для произведения сравнения значений параметров и их оценок, посчитаем численно дисперсию по формуле, выведенной в первом домашнем задании для  $N=8$ :

$$D\xi = \frac{N^2-1}{12} = \frac{64-1}{12} = 5,25$$

По полученным результатом выборочной дисперсии, мы можем видеть, что их значения стремятся к истинному значению  $D\xi$  при росте объема выборки. Это обусловлено свойством состоятельности нашей оценки.

Воспользуемся доказанным свойством состоятельности выборочного среднего, как оценки и законом больших чисел. Выразим выборочную дисперсию.

$$\begin{aligned}\hat{\mu}_2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - 2\bar{X} \frac{1}{n} \sum_{i=1}^n X_i + \frac{1}{n} \sum_{i=1}^n \bar{X}^2 = \bar{X}^2 - \bar{X}^2 \\ &\quad \bar{X}^2 \xrightarrow{P} M\xi^2 \\ &\quad \bar{X}^2 \xrightarrow{P} (M\xi)^2, n \rightarrow \infty\end{aligned}$$

Выводы по закону больших чисел. Тогда:

$$\bar{X}^2 - \bar{X}^2 \xrightarrow{P} M\xi^2 - (M\xi)^2 = D\xi, n \rightarrow \infty$$

Из этого следует, что оценка является состоятельной.

Проведем преобразования:

$$\begin{aligned} M\hat{\mu}_2 &= M(\overline{X^2} - \bar{X}^2) = M\overline{X^2} - M\bar{X}^2 \\ M\xi^2 - M\bar{X}^2 &= M\xi^2 - ((M\bar{X})^2 + D\bar{X}) \\ M\xi^2 - (M\xi)^2 - D(\frac{1}{n} \sum_{i=1}^n X_i) &= \mu_2 - \frac{1}{n^2} n\mu^2 = \frac{n-1}{n} \cdot \mu_2 \end{aligned}$$

Таким образом, мы показали что выборочная дисперсия не является несмещенной оценкой. Но путем преобразований  $M\bar{\mu}_2 = \frac{n-1}{n} \cdot \mu_2 \rightarrow M(\frac{n}{n-1} \cdot \hat{\mu}_2) = \mu_2$ . Такая оценка будет несмещенной оценкой. Так как  $\frac{n}{n-1} \rightarrow 1$  при  $n \rightarrow \infty$ , тогда данная оценка будет состоятельной.

### 3.1.2. Нахождение параметров распределений событий

Для дискретного равномерного распределения необходимо проверить условие регулярности, проверить принадлежит ли оно экспоненциальному семейству, предложить оценку  $X$  для оцениваемого параметра  $\theta$  и выполним следующее:

- Проверить, является предложенная оценка несмещенной
- Проверить, является ли предложенная оценка  $X$  состоятельной для оцениваемого параметра  $\theta$
- Проверить, является ли предложенная оценка оптимальной, эффективной. Если нет, то построить оптимальную оценку для параметра  $\theta$

Согласно условиям регулярности, дискретное равномерное распределение не относится к этой категории регулярных распределений.

Найдем оценку параметра  $\theta^*$  методом моментов ( $M[x] = \bar{X}$ ).  $M[x] = \frac{\theta+1}{2}$ .

$$1 + \theta = 2M[x]$$

$$(M[x] = \bar{X}) \rightarrow \theta = 2\bar{X} - 1$$

Дискретное равномерное распределение не принадлежит экспоненциальному семейству, так распределение может быть распределено на разных границах.

Статистика  $T = T(X)$  называется несмещенной оценкой для заданной параметрической функции, если она удовлетворяет условию:

$$M_\theta T(x) = \tau(\theta)$$

Которое называется уравнением несмещенности.

$$M[\hat{\theta}] = M[2\bar{X} - 1]$$

$$M[2\frac{1}{n}\sum_{i=1}^n X_i - 1] = \frac{2}{n}\sum_{i=1}^n MX_i - 1 = 2MX_1 - 1 = 2(\frac{\theta+1}{2}) - 1 = \frac{2+2\theta-2}{2} = \frac{2\theta}{2} = \theta$$

Статистика  $T_n = T_n(X)$  называется состоятельной оценкой для неизвестного параметра  $\tau(\theta)$  случайной величины  $\xi$ , если при  $n \rightarrow \infty$

$$T_n(x) \xrightarrow[n \rightarrow \infty]{P} \tau(\theta)$$

$$\hat{\theta} = 2\bar{X} - 1$$

$$2MX_1 - 1 = 2(\frac{1+\theta}{2} - 1) = \frac{2+2\theta-2}{2} = \frac{2\theta}{2} = \theta$$

**Исправлено:**

---

Построим оптимальную оценку. Так как максимальная порядковая статистика  $X_n$ , построим ее полоноту:

$$M_\varphi(X_n) = \sum_{i=1}^{\theta} \varphi(i)((\frac{i}{\theta})^n - (\frac{i-1}{\theta})^n)$$

Данное условие будет выполняться при условии, если  $\varphi = 0$ . Это показывает, что наша достаточная статистика будет являться полной. Тогда из этого следует, что функция  $\varphi$  от нашей достаточной полной статистики будет являться оптимальной оценкой для ее математического ожидания.

$$P(X_n \leq t) = (\frac{t}{\theta})^n$$

$$P(X_n = t) = P(X_n \leq t) - P(X_n \leq t-1) = (\frac{t}{\theta})^n - (\frac{t-1}{\theta})^n$$

$$M_\varphi(X_n) = \sum_{i=1}^{\theta} \varphi(i)((\frac{i}{\theta})^n - (\frac{i-1}{\theta})^n)$$

Займемся тем, что подберем  $\varphi$  для данного выражения. Тогда получим оценку для параметра  $\theta$ :

$$\frac{(X_{(n)}^{n+1} - (X_{(n)} - 1)^{n+1})}{(X_{(n)}^n - (X_{(n)} - 1)^n)}$$

Эффективные оценки существуют только в моделях экспоненциального семейства распределений. Выше было доказано, что дискретное равномерное распределение не принадлежит экспоненциальному семейству. Из-за этого эффективную оценку дискретного равномерного распределения найти невозможно.

Рассмотрим значения оценки по нашим выборкам, которые мы моделировали выше. Применим код написанные на Python:

```
for sample in var_list:
    sum=0
    for element in sample:
        sum += element
    print("Объем выборки = ", len(sample),',','параметр = ', 2*(sum/len(sample))-1)
```

Рис. 65: Код

Output:

Объем выборки = 5 , параметр = 8.6  
Объем выборки = 5 , параметр = 5.0  
Объем выборки = 5 , параметр = 8.2  
Объем выборки = 5 , параметр = 3.4000000000000004  
Объем выборки = 5 , параметр = 5.8  
Объем выборки = 10 , параметр = 7.4  
Объем выборки = 10 , параметр = 6.8  
Объем выборки = 10 , параметр = 7.4  
Объем выборки = 10 , параметр = 8.0  
Объем выборки = 10 , параметр = 8.6  
Объем выборки = 100 , параметр = 7.58  
Объем выборки = 100 , параметр = 7.02  
Объем выборки = 100 , параметр = 6.8  
Объем выборки = 100 , параметр = 6.38  
Объем выборки = 100 , параметр = 6.16  
Объем выборки = 1000 , параметр = 6.998  
Объем выборки = 1000 , параметр = 6.956  
Объем выборки = 1000 , параметр = 7.01  
Объем выборки = 1000 , параметр = 7.052  
Объем выборки = 1000 , параметр = 6.954  
Объем выборки = 100000 , параметр = 7.0150400000000001  
Объем выборки = 100000 , параметр = 7.0138  
Объем выборки = 100000 , параметр = 7.0055999999999999  
Объем выборки = 100000 , параметр = 6.99758  
Объем выборки = 100000 , параметр = 7.0109600000000001

Таким образом можно наблюдать свойства состоятельности оценки.

## 3.2. Экспоненциальное распределение

### 3.2.1. Нахождение выборочного среднего и выборочной дисперсии

Наиболее важными характеристиками случайной величины  $\xi$  являются ее моменты  $= E\xi^k$ , а также центральные моменты  $\mu^k = E(\xi - \alpha_1)^k$  (когда они существуют). Их статистическими аналогами, вычисляемыми по соответствующей выборке  $X = (X_1, \dots, X_n)$ , являются выборочные моменты соответственно обычные:

$$\hat{\alpha}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

и центральные:

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\alpha}_1)^k$$

$\hat{\alpha}_1$  (принято обозначать как  $\bar{X}$ ) называется выборочным средним,  $\hat{\mu}_2$  - выборочной дисперсией. Таким образом, выборочное среднее и выборочная дисперсия являются статистическими аналогами теоретических среднего (математического ожидания)  $E\xi$  и дисперсии  $D\xi$ , когда они существуют.

Для каждой выработанной ранее выборки найдем выборочное среднее и выборочную дисперсию.

Приведем только выборки размера 5 и 10, для проверки правильности вычислений:

n=5

[1.0999431208979835, 1.0231721836232246, 0.7599196398482674,  
0.6179271340547875, 1.61735966084932]  
[1.4870532313630744, 0.033117325688593054, 0.23641077941854624,  
0.17089954401185403, 0.062190229549720595]  
[0.4972709252204324, 0.037431184675976774, 0.9491365972011903,  
0.15766067799900646, 1.2195715156246898]  
[1.2400162817536216, 0.1445476361917044, 5.379479459444616,  
0.318237695566795, 0.42575782550672575]  
[0.44189005438095397, 0.05047793994970985, 1.5964832838301517,  
0.012592118419619332, 0.12387791263130578]

n=10

[1.6937133419053623, 0.007467431059613799, 1.1449982381443404, 1.2005527380539958,  
0.03218896859764006, 0.15959701523876638, 0.36626936395276394, 0.5864571179397815,  
0.35722408238000597, 0.2848703511429897]  
[0.45870925795512446, 0.6322497620353889, 0.656663340949564, 0.5649698162567983,  
2.749602197752879, 2.9663187768291603, 0.1919132588291146, 0.3971906607794735,  
1.6180916064404363, 0.9069358465901778]  
[2.839076635580519, 0.5496371206544617, 0.245077931049124, 1.6210540560099278,  
0.5916769322254678, 2.0852042848173626, 0.23049060222403164, 0.5590253617299235,  
2.3975833507441355, 1.0883281058257048]  
[0.6466203034187537, 2.323258877168198, 0.7668944874902923, 0.3629591683828057,  
1.4137436905247334, 0.2515237295013045, 0.29496782858080783, 0.2029496376522597,  
0.3005683632463297, 0.7844055847597325]  
[1.8490038172266217, 0.3170940637645764, 0.8657925833205204, 1.9785355801385411,  
0.10443322558164524, 0.16628666017878238, 0.9002243289300105, 3.460661057880038,  
0.5191491723221491, 0.16051527758322168]

Создаем функцию для вычисления выборочного среднего и дисперсии и применяем их к сгенерированным выборкам распределения.

Выборочное среднее:

n=5

Выборочное среднее - 1.0236643478547165  
Выборочное среднее - 0.39793422200635764

```

95 for i in range(15,20):
96     sum_el = 0
97     for item in var_list[i]:
98         sum_el = sum_el+item
99     raz_var = len(var_list[i])
100    it_sr = sum_el/raz_var
101    srvr_list.append(it_sr)
102    print("Выборочное среднее - ", it_sr)

```

Рис. 66: Код

Выборочное среднее - 0.5722141801442591  
 Выборочное среднее - 1.5016077796926925  
 Выборочное среднее - 0.44506426184234804

n=10

Выборочное среднее - 0.583333864841526  
 Выборочное среднее - 1.114264452441812  
 Выборочное среднее - 1.2207154380860656  
 Выборочное среднее - 0.7347891670725218  
 Выборочное среднее - 1.032169576692611

n=100

Выборочное среднее - 1.0036409006207696  
 Выборочное среднее - 0.9125987903367597  
 Выборочное среднее - 1.0577573912983125  
 Выборочное среднее - 0.9222421767232302  
 Выборочное среднее - 0.8181101465079221

n=1000

Выборочное среднее - 1.0123789911482708  
 Выборочное среднее - 0.986841483203838  
 Выборочное среднее - 0.9257189485569894  
 Выборочное среднее - 1.0666065008112484  
 Выборочное среднее - 1.0247516902652096

n=10000

Выборочное среднее - 0.9973756573027538  
 Выборочное среднее - 1.0008651681994791  
 Выборочное среднее - 1.0006799620361455  
 Выборочное среднее - 0.9979827554494645  
 Выборочное среднее - 1.0039114657998032

### Исправлено:

Как мы знаем, выборочное среднее является оценкой для математического ожидания случайной величины. С помощью формул выведенных в первом домашнем задании посчитаем математическое ожидание для  $\lambda=1$ :

$$M\xi = \frac{1}{\lambda}$$



Так как  $\lambda = 1$  тогда:

$$M\xi = \frac{1}{1} = 1$$

Из полученных нами результатов, выборочное среднее стремится к истинному значению математического ожидания при увеличении объема выборки. И это обусловлено свойством состоятельности нашей оценки, которое в свою очередь обусловлено законом больших чисел. Покажем это при помощи закона больших чисел Хинчина:

$$\frac{\xi_1 + \xi_2 + \dots + \xi_{n-1} + \xi_n}{n} \xrightarrow{P} M\xi$$

Если существует  $M|\xi_1|$  тогда:

$$\overline{X_n} \xrightarrow{P} M\xi, n \rightarrow \infty$$

Получается, что по закону больших чисел Хинчина оценка является состоятельной. Выборочное среднее обладает свойством несмещенности. Тогда покажем, что математическое ожидание от оценки будет равно истинному математическому ожиданию:

$$M\overline{X} = M\left(\frac{1}{n} \sum_{i=1}^n M(X_i)\right) = \frac{1}{n} \cdot n \cdot M\xi = M\xi$$

Мы показали, что эта оценка является несмещенной.

---

Выборочная дисперсия вычисляется с помощью кода представленного ниже:

```
191 for i in range(20,25):
192     sum_el = 0
193     sum_el_dic = 0
194     for item in var_list[i]:
195         sum_el = sum_el+item
196     for item in var_list[i]:
197         sum_el_dic = sum_el_dic+item*item
198     raz_var = len(var_list[i])
199     it_sr = sum_el/raz_var
200     it_sr_dic = sum_el_dic/raz_var-it_sr*it_sr
201     print("Выборочная дисперсия - ", it_sr_dic)
202
```

Рис. 67: Код

n=5

Выборочная дисперсия - 0.11849535515558274  
Выборочная дисперсия - 0.30192603607385826  
Выборочная дисперсия - 0.20492119562437267  
Выборочная дисперсия - 3.9011497978842025  
Выборочная дисперсия - 0.3543334061938572

n=10

Выборочная дисперсия - 0.29316372076856007  
Выборочная дисперсия - 0.8939402410046107

Выборочная дисперсия - 0.8145532508092472  
 Выборочная дисперсия - 0.40321283862274626  
 Выборочная дисперсия - 1.0650240619446356

n=100

Выборочная дисперсия - 0.7667482072721106  
 Выборочная дисперсия - 0.8706876520101826  
 Выборочная дисперсия - 1.0787992073691104  
 Выборочная дисперсия - 0.7173581077031459  
 Выборочная дисперсия - 0.7758940584735567

n=1000

Выборочная дисперсия - 1.0008941353650054  
 Выборочная дисперсия - 0.9290919423560127  
 Выборочная дисперсия - 0.8353360117857244  
 Выборочная дисперсия - 1.2901945963977102  
 Выборочная дисперсия - 1.0064003922894733

n=10000

Выборочная дисперсия - 0.9892977386306037  
 Выборочная дисперсия - 1.0057685247547912  
 Выборочная дисперсия - 1.0043502699720284  
 Выборочная дисперсия - 0.9987937557921877  
 Выборочная дисперсия - 1.0060029252580207

### Исправлено:

произведения сравнения значений параметров и их оценок, посчитаем численно математическое ожидание и дисперсию по формулам, выведенным в первом домашнем задании:

Как видно из полученных значений, при больших объемах выборки оценки выборочная дисперсия стремится к истинной дисперсии. Для произведения сравнения значений параметров и их оценок, посчитаем численно дисперсию по формуле, выведенной в первом домашнем задании для  $\lambda=1$ :

$$D\xi = \frac{1}{\lambda^2}$$

Так как  $\lambda = 1$  тогда:

$$D\xi = \frac{1}{1^2} = 1$$

По полученным результатом выборочной дисперсии, мы можем видеть, что их значения стремятся к истинному значению  $D\xi$  при росте объема выборки. Это обусловлено свойством состоятельности нашей оценки.

Воспользуемся доказанным свойством состоятельности выборочного среднего, как оценки и законом больших чисел. Выразим выборочную дисперсию.

$$\hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - 2\bar{X} \frac{1}{n} \sum_{i=1}^n X_i + \frac{1}{n} \sum_{i=1}^n \bar{X}^2 = \bar{X}^2 - \bar{X}^2$$

$$\bar{X}^2 \xrightarrow{P} M\xi^2$$

$$\bar{X}^2 \xrightarrow{P} (M\xi)^2, n \rightarrow \infty$$

Выводы по закону больших чисел. Тогда:

$$\overline{X^2} - \overline{X}^2 \xrightarrow{P} M\xi^2 - (M\xi)^2 = D\xi, n \rightarrow \infty$$

Из этого следует, что оценка является состоятельной.

Проведем преобразования:

$$\begin{aligned} M\hat{\mu}_2 &= M(\overline{X^2} - \overline{X}^2) = M\overline{X^2} - M\overline{X}^2 \\ M\xi^2 - M\overline{X}^2 &= M\xi^2 - ((M\overline{X})^2 + D\overline{X}) \\ M\xi^2 - (M\xi)^2 - D(\frac{1}{n} \sum_{i=1}^n X_i) &= \mu_2 - \frac{1}{n^2} n \mu^2 = \frac{n-1}{n} \cdot \mu_2 \end{aligned}$$

Таким образом, мы показали что выборочная дисперсия не является несмещенной оценкой. Но путем преобразований  $M\bar{\mu}_2 = \frac{n-1}{n} \cdot \mu_2 \rightarrow M(\frac{n}{n-1} \cdot \hat{\mu}_2) = \mu_2$ . Такая оценка будет несмещенной оценкой. Так как  $\frac{n}{n-1} \rightarrow 1$  при  $n \rightarrow \infty$ , тогда данная оценка будет состоятельной.

### 3.2.2. Нахождение параметров распределений событий

Для показательного распределения необходимо проверить условие регулярности, проверить принадлежит ли оно экспоненциальному семейству, предложить оценку  $X$  для оцениваемого параметра  $\theta$  и выполним следующее:

- Проверить, является предложенная оценка несмещенной
- Проверить, является ли предложенная оценка  $X$  состоятельной для оцениваемого параметра  $\theta$
- Проверить, является ли предложенная оценка оптимальной, эффективной. Если нет, то построить оптимальную оценку для параметра  $\theta$

Два условия принято называть условиями регулярности:

- Существует такой носитель семейства распределений  $F_\theta$ , что при каждом  $x \in C$  функция  $\sqrt{f_\theta(y)}$  непрерывно дифференцируема по  $\theta$  всюду в области  $\Theta$
- Информация Фишера  $I(\theta) = E(\frac{\partial}{\partial \theta} \ln f_\theta(X_1))^2$  существует, положительна и непрерывна по  $\theta$  во всех точках  $\theta \in \Theta$

Статистика  $T = T(X)$  называется несмещенной в среднем (или просто несмещенная) оценкой для заданной параметрической функции  $\tau(\theta)$ , если она удовлетворяет условию

$$M_\theta T(X) = \tau(\theta), \forall \theta \in \Theta$$

которые называется уравнением несмещенности.

$$M\hat{\theta} = M\bar{X} = MX_1 = \frac{1}{\lambda}$$

Найдем оценку параметра  $\theta^*$  методом максимального правдоподобия.

$$L(\theta, x) = \prod_{i=1}^n \theta e^{-\alpha x_i} = \theta^n e^{-\theta \sum_{i=1}^n x_i}$$

Воспользуемся условием максимума  $\frac{dL(\theta, x)}{d\theta} = 0$ . И получим следующее уравнение:

$$n\theta^{n-1}e^{-\theta \sum_{i=1}^n x_i} - \theta^n \sum_{i=1}^n x_i e^{-\theta \sum_{i=1}^n x_i} = 0$$

Отсюда следует  $\theta^* = \frac{1}{\frac{1}{n} \sum_{i=1}^n x_i}$ . Откуда  $\tau(\theta) = \hat{\theta} = \bar{X}$

Найдем теперь оценку параметра  $\theta^*$  методом моментов.

$\mu_1(\theta) = M[x] = \int_0^\infty x\theta e^{-\theta x} dx = \frac{1}{\theta}$  Приравниваем к  $m_1 = \frac{1}{n} \sum_{i=1}^n x_i$ . Отсюда получаем  $\theta^* = \frac{1}{m_1} = \frac{1}{\frac{1}{n} \sum_{i=1}^n x_i}$ . Таким образом, оценки параметра  $\theta$  полученные методом максимального правдоподобия и методом моментов совпали.

Статистика  $T_n = T_n(X)$  называется состоятельной оценкой для неизвестного параметра  $\tau(\theta)$  случайной величины  $\xi$ , если при  $n \rightarrow \infty$

$$T_n(x) \xrightarrow[n \rightarrow \infty]{P} \tau(\theta)$$

$$\bar{X} \xrightarrow[n \rightarrow \infty]{P} MX_1$$

$$\hat{\theta} = \bar{X} \xrightarrow{P} MX_1$$

$$\hat{X} \xrightarrow{P} MX_1 = \frac{1}{\lambda}$$

Эффективные оценки существуют только в моделях экспоненциального семейства распределений. А именно, если

$$L(x, \theta) = h(x) \cdot \exp[A(\theta) \cdot U(x) + B(\theta)]$$

то существует эффективная оценка  $T(x) = U(x)$  параметрической функции

$$\tau(\theta) = -\frac{B'(\theta)}{A'(\theta)}$$

$$L(x, \theta) = 1 \cdot [-\theta n \cdot \bar{X} + n \ln \theta]$$

Откуда следует  $U(x) = \bar{X}$

$$\tau(\theta) = -\frac{\frac{n}{\theta}}{-n} = \frac{1}{\theta}$$

Мы показали, что оценка является эффективной, а значит оптимальная и единственная.

Рассмотрим значения оценки по нашим выборкам, которые мы моделировали выше. Применим код написанные на Python:

Output:

Объем выборки = 5 , параметр = 4.4

```

for sample in samples_list:
    sum=0
    for element in sample:
        sum += element
    print("Объем выборки = ", len(sample),',','параметр = ', sum/len(sample)-1)

```

Рис. 68: Код

Объем выборки = 5 , параметр = 1.7999999999999998  
 Объем выборки = 5 , параметр = 4.2  
 Объем выборки = 5 , параметр = 2.4  
 Объем выборки = 5 , параметр = 4.8  
 Объем выборки = 10 , параметр = 1.9  
 Объем выборки = 10 , параметр = 3.0999999999999996  
 Объем выборки = 10 , параметр = 3.4000000000000004  
 Объем выборки = 10 , параметр = 3.2  
 Объем выборки = 10 , параметр = 2.6  
 Объем выборки = 100 , параметр = 3.2300000000000004  
 Объем выборки = 100 , параметр = 3.3499999999999996  
 Объем выборки = 100 , параметр = 3.4400000000000004  
 Объем выборки = 100 , параметр = 3.58  
 Объем выборки = 100 , параметр = 3.2  
 Объем выборки = 1000 , параметр = 3.4989999999999997  
 Объем выборки = 1000 , параметр = 3.5570000000000004  
 Объем выборки = 1000 , параметр = 3.458  
 Объем выборки = 1000 , параметр = 3.5780000000000003  
 Объем выборки = 1000 , параметр = 3.4749999999999996  
 Объем выборки = 10000 , параметр = 3.492  
 Объем выборки = 10000 , параметр = 3.5092999999999996  
 Объем выборки = 10000 , параметр = 3.4665999999999997  
 Объем выборки = 10000 , параметр = 3.5395000000000003  
 Объем выборки = 10000 , параметр = 3.5204000000000004

Таким образом можно наблюдать свойства состоятельности оценки.